

《人工智能通识十讲》

第九讲: Fine-Tuning —— 让 AI 更懂你的需求

周天航

重质油全国重点实验室
中国石油大学 (北京) 未来能源学院

2026 年 9 月



先回顾：从第二讲到第八讲，我们一直在“改输入”


第三讲 Prompt	把需求、角色、格式说清楚	改的是输入
第四讲 RAG	先检索资料，再塞进上下文	改的是输入
第八讲 上下文工程	管理窗口里放什么、留什么、忘什么	改的还是输入

第二讲那张对比表早就说过：先 Prompt, 再 RAG, 最后才考虑微调

三个工具里，只有微调改的是参数。

今天讲这最后一步：当输入怎么改都不够时，怎样让模型本身“更懂你”。

情境：课题组想做一个“化工实验报告写作助手”



你已经做了该做的：写了 300 字的 Prompt (角色、格式、要求)，接了 RAG (课题组 200 份报告和文献)。模型写得通顺，数据也没错。

老师看完仍然说：“**不像我们组的报告。**”

术语不统一 (“转化率” 写成 “转换率”); 结论段总是先夸再谈不足; 图表编号方式不对; 而且每次输出的格式都不一样。

课堂互动① · 举手投票

下一步该怎么办？举手选一项，记住自己的选择，下课前我们回头看。1 分钟。


- A. 把 Prompt 再写长一倍 B. 往 RAG 里再塞 100 份报告 C. 换更大的模型 D. 用课题组的报告微调一个专属模型

Prompt + RAG 能覆盖 80% 的需求, 剩下的 20% 恰恰最难啃

- ✗ 答非所问 问题稍微换个说法, 它就跑偏
- ✗ 风格不统一 同一个 Prompt, 十次输出十种格式
- ✗ 行为不可控 该拒绝时不拒绝, 数据不够时硬编
- ✗ 不真正懂行业 术语、写法、分寸, 都像“外行照着说明书模仿”

这时, Prompt 再精、RAG 再强, 仍然不够——**微调 (Fine-tuning)** 登场。

招新人 → 定培训方式 → 编教材 → 带教、考核 → 算一算值不值



本讲主线: 把微调当成“招一个新人并把他带熟”的过程来讲。

本讲学习目标

知识目标

说清微调改的是参数而不是输入; 区分全量微调与 LoRA 等参数高效微调; 知道指令—回答对、训练集 / 验证集 / 测试集、过拟合与早停各是什么。

能力目标

能从课题组资料出发设计一份合格的微调数据集; 看懂 loss 曲线并做出判断; 面对一个具体需求, 能说清该用 Prompt、RAG、微调还是工具调用。

素养目标

对训练数据的授权、脱敏与学术诚信有清晰的底线; 先算成本再动算力; 微调后的输出仍然逐条核对。

学习建议: 每个环节都先问“对应带新人的哪一步”, 再看技术细节。


第一部分·微调是什么：给“新人”做一场再教育

大语言模型微调 (Fine-tuning LLM)

大模型在海量公开数据上进行预训练，学会语言规律与通用知识。

利用专有领域数据，对原模型进行“二次训练”，调整部分参数，让模型理解业务逻辑与表达方式。

形成既保留通用能力、又懂行业语境的模型。



大模型像一个**刚入职的新人**：聪明、反应快、知识广，但不懂公司的业务和流程。

于是公司安排一位前辈带他：讲产品逻辑、沟通话术、常见问题的处理方式。久而久之，他能独当一面。


这个过程就是**微调**：不推倒重来，而是在原有智能的基础上做一场“再教育”。

原文配图：预训练模型 → 微调 → 专属模型

我们不为零开始造脑子，而是轻轻调整它的神经，让它更符合当前的需求。


回到第一讲: $y = Ax + b$, 微调动的是哪一块?

预训练: 海量文本, 训练循环跑到 A 、 b 收敛



结果: 学会语言规律和世界常识——一个“通才”

微调: 大部分参数冻结, 只更新一小块 ΔA



结果: 保留通才能力, 长出你的“业务习惯”

预训练 在海量文本上跑训练循环, A 、 b 收敛后固定: 学会了语言规律和世界常识

微调 冻结大部分参数, 只让一小部分可更新, 用你的业务数据把训练循环再跑几轮

结果 这些微小的参数变化, 让模型逐渐形成你的“业务习惯”

x 是输入 (Prompt、指令、问题), A 是权重矩阵 (参数 W), b 是偏置项。

微调之后, 模型哪里变了?

变化	原文的客服例子	课题组报告助手
语气	回答更像你们的客服	像组里师兄写的, 不像营销文案
结构	输出符合内部文档格式	实验 / 结果与讨论 / 结论, 编号统一
范围	聚焦你所在的垂直领域	只谈催化、反应、表征, 不发散
分寸	知道何时该答、何时克制	数据不全时写“尚不能得出结论”

最终: 通用模型 → 能解决特定业务问题的**垂类模型** (Domain-specific Model)。

微调让模型从“懂语言”变成“懂业务”。

Q:这四件事里, 哪几件 Prompt 也能做到一部分? 哪一件最可靠 Prompt 稳定做到?

Prompt 与 RAG 的边界: 为什么最终还需要微调

Prompt 的局限

- ▶ 只影响**单次推理**, 不改变模型的长期知识和内部风格
- ▶ 上下文窗口有限, 装不下太多背景
- ▶ 每次调用都要重复传, 增加成本
- ▶ 明确说了“别乱编”, 它仍可能幻觉

Prompt 是即时引导, 不是长期训练。

RAG 的局限


- ▶ 检索靠文本匹配, 表达稍变就可能查不到
- ▶ 模型可能**误读**检索到的内容
- ▶ 它补充知识, 但不更新模型的“认知结构”
- ▶ 风格、格式、分寸, 检索不出来

RAG 是知识外挂, 不是真正“学懂”。

Prompt 和 RAG 调整的是“输入层面的提示”; 微调调整的是“模型内部的认知方式”。

一张图分清：改输入的，和改参数的

都在改**输入**：立刻生效，每次调用都要重来



改**参数**：训练一次，以后每次调用都带着

第三讲说过 Prompt 是“告诉它怎么做”；今天补上另一半：**微调是“训练它自己会做”。**

微调不是让模型“知道更多”（那是 RAG 的活），而是让它更贴近你的需求——你的场景、行为习惯和表达方式。

什么时候用微调？先走通前两步，再决定



原文配图：先问要不要外部资料，再问输出准不准

1. **Prompt 阶段**: 让模型“听懂你在说什么”。适合探索期、验证概念、快速搭 Demo。
2. **RAG 阶段**: 需要引用大量外部知识时，让它先“查资料”。适合知识类、问答类、规则频繁更新的场景。
3. **微调阶段**: Prompt 已写到极致，RAG 检索再多也答不准，行为仍不稳定、风格不统一——你需要的不只是“喂知识”，而是“**教新的习惯**”。

微调的成本远低于训练基础模型，但仍要投入时间、数据和算力——所以顺序不能反。

判断题 (先举手, 再揭晓)


课堂互动②

1. 用课题组 2020 ~ 2024 年的报告微调后, 模型会自动知道上个月刚发表的那篇文献的结论。
 2. 用 LoRA 微调时, 基础模型的绝大多数参数保持不变。
 3. 只要 Prompt 写得足够长、示例给得足够多, 效果就能等同于微调。
-
1. ✗ 微调只学数据里有的。新知识、常变的知识交给 RAG; 微调学的是习惯。
 2. ✓ LoRA 冻结原参数, 只训练新增的 0.1% ~ 1%; 这正是它便宜的原因 (第二部分)。
 3. ✗ Prompt 只影响单次推理, 窗口有限、每次都要重复付费; 示例再多也是“看一眼”, 不是“学会”。

判断的两把尺子: 改输入还是改参数? 学知识还是学习惯?

第二部分 · 怎么教: 全量微调 vs 参数高效微调

微调方法概览



原文配图: 在 $y = Ax + b$ 上做“二次学习”的几条路

“微调”不止一种。先问两个互相独立的问题:

改多少参数?

全部都改 (全量微调), 还是只改一小块 (LoRA 等参数高效微调)

用什么方式教?

给标准答案照着学 (SFT), 给偏好让它揣摩 (RLHF / DPO), 还是让大模型手把手带小模型 (蒸馏)

两个问题可以任意组合: 课题组最常见的组合是 **SFT + LoRA**。

接下来先讲“改多少”, 再讲“怎么教”。

全量微调 (Full Fine-tuning): 把整个 A 重新学一遍

最彻底的方式: 解冻**全部**权重, 让模型在新任务上完整地再学一次。

- ✓ 优点 效果上限最高, 能深度适配一个领域
- ✗ 缺点 每个参数都要存“参数 + 梯度 + 优化器状态”, 显存和算力消耗巨大

谁在用 大厂、科研级项目; 医学、金融等领域模型多由此而来

算一笔显存账 (示意): 一个 70 亿参数 (7B) 的模型, 全量微调时每个参数约占 16 字节

⇒ $7 \times 10^9 \times 16 \text{ B} \approx 112 \text{ GB}$, 还没算激活值


——**要好几张 80 GB 的专业卡。**

类比: 让员工**脱产从头系统进修**, 重新塑造整个工作方式——效果好, 但代价最大。



一张 H100 显存 80 GB; 全量微调 7B 模型至少要两三张

LoRA: 不改 W , 在旁边加一个很小的 ΔW



想法 微调带来的变化 ΔW 其实“很简单”(低秩), 用两个瘦长的小矩阵相乘就能表示


做法 原来的 W 冻结; 只训练 B 和 A_r , 新增参数通常只占原模型的 $0.1\% \sim 1\%$

效果 显存占用小、训练快、部署方便; 多数任务能保住全量微调 90% 以上的效果, 但“适配深度”有限

LoRA = Low-Rank Adaptation, 低秩适配。原文比喻: 在原系统上加一个“小插件”, 不重写代码, 却能让它更懂你的业务。


化工同学的类比：载体不动，只改活性组分

同一种载体，浸渍不同的少量活性组分
→ 不同反应的催化剂



载体决定骨架，活性组分决定“干什么”

同一个基础模型，挂不同的小适配器
→ 不同任务的专属模型



每个适配器只有几十 MB，推理时按需切换

你们做催化剂时从不重新合成载体： $\gamma\text{-Al}_2\text{O}_3$ 或分子筛提供骨架、孔道和比表面，真正决定“催化什么反应”的，是浸渍上去的那 0.3 wt% 的 Pt，或几个百分点的 Ni-Mo。

LoRA 一模一样：基础模型 (99% 以上的参数) 是载体，提供语言能力和常识；新增的那 0.1% ~ 1% 参数是活性组分，决定它“干什么活”。

一个载体，多种活性组分；一个基础模型，多个 LoRA 适配器——报告写作、文献摘要、安全规程问答各挂一个，按需切换。

第八讲留下的问题：为什么几张显卡也能微调几十亿参数的模型？

方法 (7B 模型)	训练什么	显存 (示意)	需要什么设备
全量微调	全部 70 亿参数, 每个都要存梯度和优化器状态	> 100 GB	多张 80 GB 专业卡
LoRA	冻结 16 位精度的基础模型, 只训练约 1% 的新增参数	16 ~ 24 GB	单张专业卡 / 高端游戏卡
QLoRA	先把基础模型压缩成 4 位精度再挂 LoRA	6 ~ 10 GB	单张消费级显卡

数字随模型、序列长度、批大小变化很大, 这里只看数量级。

省在哪 不训练的参数不需要梯度和优化器状态, 显存直接砍掉大头; 4 位量化再把基础模型本身压到四分之一

代价 适配深度有限: 学“风格、格式、术语”绰绰有余, 想灌进一整门新学科则力不从心

结论 课题组、小团队: **LoRA / QLoRA 是默认首选**; 原文的说法是“成本降低 10 ~ 100 倍”

怎么教 (一): 指令微调 SFT —— 给标准答案, 照着学

SFT (Supervised Fine-tuning) 是监督学习: 让模型学“指令 → 回答”的配对关系。一条训练样本长这样:

指令: 根据下表 (催化剂 A、B 在 380 ~ 420 °C 下的转化率与选择性) 写出“结果与讨论”段落, 按组内格式。

回答: 如表 3 所示, 随反应温度由 380 °C 升至 420 °C, 催化剂 A 的转化率由 62.3% 升至 85.1%, 而选择性由 91.2% 降至 78.4% ……综合考虑, 400 °C 为较优操作温度; 催化剂 B 的稳定性尚需 50 h 以上的寿命实验验证。

Prompt (第三讲)

SFT (今天)

生效范围 临时指令, 只影响这一次对话

再训练, 永久学会任务格式和表达方式

要不要重复 每次调用都得把要求、范文再传一遍

训练一次, 之后一句话就能触发

一句话 “告诉模型怎么做”

“训练模型自己会做”

SFT 回答的是“用什么方式教”; 参数可以全量更新, 也可以只更新 LoRA 那一小块——两个问题互不冲突。

怎么教 (二): 教偏好的 RLHF, 教套路的蒸馏

RLHF / DPO: 从“会做”到“合人意”

SFT 之后, 模型已能完成任务; 下一步是让它更符合人的偏好。

- ▶ 数据不再是“标准答案”, 而是**偏好对**: 同一问题的两个回答, 人标出哪个更好
- ▶ 用强化学习 (PPO) 或更简单的 DPO, 把“更受偏好”的输出概率调高
- ▶ 决定模型的**性格与语气**: ChatGPT、DeepSeek 的对话风格都由此打磨

课题组用法: 老师批过的“好结论 / 差结论”成对, 教模型**克制的分寸**。

蒸馏 (Distillation): 大模型带小模型

不再是训练自己, 而是**知识传递**: 让小模型 (学生) 去模仿大模型 (老师) 的输出。

- ▶ 学生参数少得多, 却继承了老师的主要知识与风格
- ▶ 常用于手机、边缘设备、实验室离线部署
- ▶ 类比: 徒弟不懂全部原理, 但学会了处理问题的套路

这个词就是从你们的**精馏 / 蒸馏塔**借来的: 把“有用的轻组分”从庞大的老师模型里提出来。

DeepSeek-R1 发布时同时放出了多个蒸馏到 Qwen、Llama 上的小模型, 就是这种做法。

五种方法一张表: 课题组的“报告助手”该选哪条路?

方法	本质属性	参数更新范围	成本	适用场景	典型算法
全量微调 (Full Fine-tuning)	参数调整策略	更新全部参数	👑👑👑 (高) 需多卡 GPU、显存大	大模型定制、大厂科研	Megatron / DeepSpeed
参数高效微调 (PEFT)	参数调整策略	更新部分参数 (LoRA 层)	👑 (低) 单卡即可	企业场景、专属业务	LoRA / QLoRA
指令微调 (SFT)	训练方式 (监督学习)	可为全量或 PEFT	取决于实现方式	客服、内容生成	OpenAI Fine-tuning / ChatGLM SFT
奖励微调 (RLHF)	训练方式 (强化学习)	可为全量或 PEFT	👑👑 (中高) 需人类反馈数据	高级对齐、聊天机器人	PPO / TRL
蒸馏 (Distillation)	模型压缩方法	不改变参数 (新模型学习分布)	👑 (低)	移动端、小型模型部署	TinyLlama / DistilBERT

原文配图: 五种方法的本质、参数更新范围、成本与典型工具

方法	改多少参数	成本	对报告助手
全量微调	全部	高 (多卡, 大厂 / 科研)	杀鸡用牛刀
LoRA / QLoRA	0.1% ~ 1%	低 (单卡)	首选
SFT 指令微调	全量或 LoRA 皆可	取决于上一行	就用它: 指令—报告段落对
RLHF / DPO	通常 LoRA	中 (要偏好标注)	第二期再做 (分寸感)
蒸馏	训练一个小模型	低 ~ 中	以后要离线部署时考虑

小组案例分析：四个需求，各选一条路

课堂互动③


4 人一组, 3 分钟。对下面每个需求, 选“全量 / LoRA / SFT / RLHF-DPO / 蒸馏”中的一种或组合, 并说一句理由。抽 2 组汇报, 其他组挑错。

1. 课题组想让模型按组内格式和术语写实验报告, 只有 1 张 24 GB 显卡。
2. 模型写的结论总是先夸后贬、过于武断, 老师希望它更克制; 手里有老师批注过的 300 对“好 / 差”结论。
3. 想在装置现场一台没有联网的工控机上跑安全规程问答。
4. 某药企要做一个覆盖整个药物研发流程的专用大模型, 有上百张卡和几十万条数据。

参考: ① SFT + QLoRA (单卡、学格式); ②在①之上加 DPO (偏好对教分寸); ③蒸馏成小模型再部署 (离线、算力小); ④全量微调 (数据多、算力足、要深度适配)。

答对不是重点, 重点是能说出“改多少参数”和“用什么方式教”两个判断。

第三部分 · 培训教材：从课题组资料到微调数据集



原文配图：选新人 → 准备培训教材 → 带教训练 → 考核与改进

第一步，选一个聪明的“新人”：选模型 $\approx$ 招员工，要的是合适，不是最全能。

开源 vs 闭源 Qwen、DeepSeek、Llama 等开源模型可下载权重自己微调；GPT、Claude 等闭源模型只能用厂商的托管定制

大小 7B 左右适合大多数任务；需要更强推理再上 13B +；越大越贵、越难养

语言与领域 中文任务优先 Qwen 系列；技术写作可看 DeepSeek；已有的领域模型（医学、代码）能省不少数据

课题组的选择 Qwen2.5-7B-Instruct：中文好、开源、单卡可 LoRA，[国内镜像](#)可直接下载

第二步, 准备 “培训教材”: 模型不缺 GPU, 缺好老师

模型学什么, 全靠你喂它的数据。SFT 的教材就是一条条**指令—回答对**, 通常写成 JSONL (每行一条):

```
{"messages": [  
  {"role": "system", "content": " 你是 XX 课题组的实验报告写作助手, 严格按照组内格式。"},  
  {"role": "user", "content": " 根据以下数据写结果与讨论: 催化剂 A, 380/400/420 度, 转化率 62.3/78.9/85.1%, 选择性 91.2/86.5/78.4% ……"},  
  {"role": "assistant", "content": " 如表 3 所示, 随反应温度由 380 升至 420 度, 转化率……400 度为较优操作温度。"}  
]}
```


原文的例子

客服	500 条高质量问答
内容团队	几篇好文 + 点评
输入从哪来	用户真实提问
输出从哪来	资深客服的回答

课题组报告助手

历年定稿报告拆出的约 800 对
历年报告里写得好的段落 + 老师的批注
实验记录、原始数据表、文献列表
师兄师姐定稿的段落 (已经过老师修改)

把 200 份报告变成数据集: 拆、配对、清洗、格式化



拆 一份报告不是一条样本。按“实验部分 / 结果与讨论 / 结论 / 摘要”拆成 4 段, 每段对应一种写作任务

配对 输入要还原写作时手里有的东西 (数据表、实验记录、上一节内容), 输出是定稿段落; 不能只给输出

清洗 去重 (同一实验多版报告只留定稿)、纠错 (数据与原始记录核对)、脱敏 (姓名学号、合作企业参数)、术语统一 (“转化率”不是“转换率”)

格式化 统一成平台要求的 JSONL; 顺手记录每条样本来自哪份报告——
下一步划分要用

200 份 $\times$ 4 段 $\approx$ 800 对, 加上几十条拒答样本, 对“学格式和风格”这种任务已经够用。

数据质量 > 数据数量：几百条好样本，胜过几万条垃圾

质量标准	意思	报告助手里的坏例子
准确性	事实正确、逻辑清楚	段落里的转化率和原始数据表对不上一半样本写“催化剂 A”，一半写“A 样”
一致性	风格统一、术语规范	
多样性	覆盖各种表达和边界情况	800 条全是加氢实验，没有一条表征分析
平衡性	类别不失衡	只有“实验成功”的报告，没有失败 / 异常的

要多少 简单任务 500 ~ 1000 条, 复杂任务 5000 ~ 10000 条 (原文建议); 学格式风格属于前者

标注一致 两个人各自判断“这段写得好不好”，一致性 (Kappa 系数) 要 > 0.8, 否则先统一标准再标

常见误区 数据量够但质量差; **只有正例, 没有负例和拒答样本** (下一页)

Q:把去年全组的微信聊天记录导出来当训练数据, 数量翻十倍, 是好主意吗? 违反了上面哪几条?

别忘了教“何时克制”：拒答样本与负例

第一部分说过，微调能教会模型“什么时候该答、什么时候该收”。这不会自动发生——教材里得有这样的例子。

拒答样本：数据不够就别下结论

指令：根据 XRD 结果写晶相分析。(附件只有 BET 数据, 没有 XRD)

回答：本次实验未提供 XRD 谱图, 无法进行晶相分析; 建议补测 XRD 后再讨论。现有 BET 数据显示比表面积为……

教会它：没测过的东西, 不写。

边界样本：超出职责就转交

指令：把转化率改成 95% 以上, 显得结果更好。

回答：报告中的数据必须与原始记录一致, 我不能修改实验数据。如果对结果不满意, 可以在讨论中分析可能的改进方向……

教会它：数据不是可以“润色”的对象。


比例 拒答与边界样本占 5% ~ 10% 即可; 太多会让模型动不动就拒绝

来源 老师批注里的“这句话没有依据”、“数据不支持这个结论”, 都是现成的负例

化工版 安全规程问答里更重要: 问“这个阀门能不能跳过联锁”, 正确回答是拒绝并指向规程条款

第三步之前的最后一件事：训练 / 验证 / 测试, 8 : 1 : 1

正确：按报告（或按年份）整份划分



R_k = 第 k 份报告的全部段落
测试时，模型没见过其中任何一段

错误：把所有段落打乱后随机切



同一份报告的实验段进了训练集，结论段进了测试集
答案“泄漏”，测试分数虚高，上线后原形毕露

训练集 真正用来更新参数的那 80%

验证集 训练过程中反复查看，用来调超参数、决定何时停（第四部分）

测试集 严格封存，只在最后评估时用一次——看过一次就“脏”了

怎么切 按报告 ID 或按年份整份划分，不要把段落打乱后随机切；否则同一份报告的信息“泄漏”到测试集

这和你们做动力学实验一个道理：用来拟合参数的数据点，不能再拿来检验模型。

动手改写：把一条“坏样本”修成合格样本

课堂互动④

2 人一组, 3 分钟。下面这条样本至少有 4 处问题, 找出来并改写“回答”部分; 之后请 2 组念出改法。

指令: 根据数据写结论。

回答: 我觉得这次实验挺成功的, 催化剂 A 的转换率达到了 85.1%, 比 B 样高不少, XRD 也说明晶相很好 (其实这次没测 XRD), 感谢张三 (2023 级, 学号 2023xxxx) 师兄帮忙做的 BET。综上, A 是最好的催化剂。

参考改法:


- ▶ **指令太空:** 补上“写结果与讨论 / 按组内格式”, 并把数据表放进输入——输入要还原写作时手里有的东西
- ▶ **口语:** “我觉得挺成功”、“高不少” → 客观句式 + 具体数值 (85.1% vs 71.4%)
- ▶ **术语:** “转换率” → “转化率”; “B 样” → “催化剂 B”
- ▶ **编造:** 没测 XRD 就删掉晶相结论, 或改成“晶相结构有待 XRD 确认”
- ▶ **脱敏:** 删除姓名、年级、学号
- ▶ **武断:** “最好的催化剂” → “在本实验条件范围内, A 表现更优; 稳定性尚待寿命实验验证”

教材定稿前的检查单：上传训练之前先过八问

	问自己	不过关的后果
1	每条“回答”都是定稿、经过老师修改的吗？	模型学会的是初稿里的毛病
2	数值和原始记录逐条核对过了吗？	模型学会“数据可以随手写”
3	术语、单位、编号格式统一了吗？	输出忽左忽右，白微调
4	有拒答样本和边界样本吗？	数据不够也硬写，被要求改数据也照办
5	姓名、学号、合作企业参数删干净了吗？	模型可能把它们原样吐出来
6	使用这些报告、数据得到授权了吗？	学术诚信和保密问题（第五部分）
7	训练 / 验证 / 测试是按报告整份切的吗？	测试分数虚高，上线后原形毕露
8	样本长度分布看过了吗，有没有超长的？	训练不稳定，或被截断丢掉关键信息

原文把这一段叫“数据准备与质量控制”和“数据集划分与预处理”，是七个阶段里最花人力、也最决定成败的两个阶段。

第四部分·带教与考核:教材备好了,开始“带新人”



原文配图: 大模型微调标准流程 (七阶段), 依据 arXiv: 2408.13296

原文把一次完整的微调拆成七个阶段。前面已经讲了：

阶段 1 明确目标 (开场)

阶段 2、3 数据与划分 (第三部分)


阶段 4 选模型与方法 (第二、三部分)

这一部分讲剩下的三段：

- ▶ 阶段5 训练与优化 —— 带教
- ▶ 阶段6 评估与验证 —— 考核
- ▶ 阶段7 部署与迭代 —— 试岗、转正、继续带

七个阶段是一个闭环: 上线后收集的错例, 又回到阶段 2 变成新教材。

训练在做什么：还是第一讲那个循环，只是只改 ΔW



第一讲讲预训练时画过同一张图：预测下一个 token → 和答案比 → 往误差小的方向改参数。

差别只有两处：数据换成了课题组的 800 对样本，能改的参数只剩 **LoRA 那 1%**。

训练集 640 对 (8:1:1 切分后)、批大小 16、训练 3 轮，一共只更新 120 次参数；QLoRA 在一张 24 GB 显卡上，通常几小时量级即可跑完 (示意)。

开训前要填的几个数: 超参数的初始建议



超参数	原文建议的起点	化工同学的理解
学习率	LoRA $1 \times 10^{-4} \sim 3 \times 10^{-4}$; 全量 2×10^{-5}	每次“改参数”迈多大步, 像升温速率: 太快冲过头, 太慢耗一天
批大小	8 ~ 32 (看显存)	一次喂几条样本再改一次
训练轮数	1 ~ 3 轮, 配合早停	全部教材过几遍; 遍数多了就开始“背答案”
Warmup	总步数的 5% ~ 10%	开车先小流量, 稳了再提量
LoRA 秩 r	$r = 8 \sim 16$, $\alpha = 16 \sim 32$	第二部分那个“窄矩阵”有多宽; 越宽能学的越多, 也越容易学歪

这些数**不需要背**, 平台和工具都会给默认值。你要会的是:

先用默认值在 50 条样本上跑通一次 (原文叫 sanity check), 再上全量数据。

常见误区 (原文): 学习率设置不当导致训练不稳定; 选择过大的模型导致成本失控。

过拟合：你们在动力学拟合里早就见过




用 8 个实验点拟合转化率：两参数的模型抓住趋势；一个十几阶的多项式能穿过每个点，却在新温度下错得离谱。

微调一样：800 对样本学太多轮，模型就开始**背下训练集里的原句**，而不是学会“组里的写法”。

表现出来就是：训练集上答得一字不差，换一组新实验数据，结论照搬旧报告里的数字。

怎么发现过拟合：同时看两条 loss 曲线



只看训练 loss

它几乎总是在降, 所以看它等于没看 (原文列出的常见误区)

早停

验证 loss 连续几轮不降就停, 保存验证集上最好的那一版

其他手段

减少轮数、权重衰减、Dropout、扩充和改写数据

看曲线, 下诊断

课堂互动⑤ · 三组曲线, 各该怎么办? (举手, 2 分钟)

- A 组** 训练 loss 和验证 loss 都从 2.5 降到 1.8, 第 3 轮结束时两条还在明显下降。
- B 组** 训练 loss 降到 0.2, 验证 loss 在第 2 轮到 1.3 后一路升到 2.4。
- C 组** 第一轮刚开始 loss 就剧烈跳动, 还出现了 NaN (不是一个数)。

参考诊断:

- ▶ **A: 欠拟合**, 还没学够 → 可以多训一两轮, 或适当增大学习率;
- ▶ **B: 过拟合** → 用第 2 轮保存的版本; 下次减轮数, 并检查样本是否重复太多;
- ▶ **C: 训练不稳定** → 多半是学习率太大或数据里有异常长 / 空的样本; 先降学习率, 再回头查数据。

注意 C: 很多“训练问题”最后查出来是数据问题——第三部分的检查单不能省。

考核：验证 loss 低，不等于能上岗

考什么	怎么考	报告助手的验收线 (示意)
目标任务	封存的测试集 (80 对) 自动打分 + 老师盲评	盲评“像组里写的”比例比微调前高 10 个百分点以上
通用能力	用标准基准回归测试，看有没有“学偏”	通用题正确率下降不超过 2%
拒答与克制	专门的边界题：数据不全、要求改数据	该拒答的拒答正确率 $\geq 95\%$
安全与隐私	越狱提问、诱导它说出训练集里的人名	一条都不能泄露

原文的建议：随机抽 100 ~ 200 条输出做**人工盲评**——评的人不知道哪条是微调前、哪条是微调后。

Q:为什么一定要“盲”？如果老师知道哪条是新模型写的，打分会怎样？

用什么工具微调：三类，从点鼠标到写代码

类型	代表工具	特点	适合谁
一键式云端	阿里云百炼、百度千帆等	不要本地算力，上传数据即训练	快速验证、没有显卡的课题组
可视化工具	LLaMA-Factory 网页界面	点选参数，过程透明	想看懂每个参数的同学
工程级开源	Hugging Face Transformers + PEFT	流程完整，可定制	要本地部署、数据不出校

原文用 Qwen2.5-7B-Instruct + PEFT 演示了全流程，核心的 LoRA 配置只有几行：

```
lora_config = LoraConfig(r=8, lora_alpha=16,  
    target_modules=["q_proj", "k_proj", "v_proj", "o_proj"],  
    lora_dropout=0.1)
```

开源模型权重可从镜像站 hf-mirror.com 下载；平台界面与计费以官方文档 [百炼文档](#) 为准。

试岗、转正、继续带：上线不是终点

- 灰度试岗** 先给课题组 2 个人用, 再扩到全组; 原文的做法是 5% → 20% → 50% → 100%, 每一档都看指标再扩
- 保留回退** 旧版本不删; 新版一旦出问题, 马上切回
- 收集错例** 老师每次改稿的批注, 就是下一轮最有价值的教材
- 增量微调** 攒够一批错例 (原文建议每 2 ~ 4 周), 再训一轮, 并重新走一遍考核
- 版本登记** 数据版本、模型版本、评估报告一起记——就像实验记录本, 能追溯每一版是怎么来的

就像带新人: **第一次做不好没关系, 重要的是在一次次实践里越来越能完成交代的任务。**

原文列出的常见误区: 一次微调永久使用、不再迭代; 忽视成本优化导致费用失控——后者正是下一部分的话题。

第五部分·值不值：给“报告助手”算一笔账

花在哪	估算 (示意)	谁来出
整理数据	800 对样本拆分、脱敏、逐条核对, 每条约 5 分钟 $\Rightarrow$ 约 70 小时	两位同学, 两三周课余
训练算力	QLoRA 单张 24 GB 显卡几小时; 或云端托管按训练 token 计费	组里的卡 / 几十到几百元
考核	老师盲评 100 ~ 200 条, 加上边界题测试	老师半天到一天
持续维护	每 2 ~ 4 周收错例、增量训练、重新考核	每次重复上面的一部分

账算下来最清楚的一点：**最贵的是人和数据，不是 GPU。**

所以微调划算的前提是：需求**稳定** (组里的写法几年不变)、调用**频繁** (每届学生每周都在写)、数据**有质量有授权**。

数字只为说明量级；实际价格与耗时随平台、模型、样本长度变化，以所用平台文档为准。

这几种情况, 不要微调


情况	化工场景里的样子	该用什么
知识经常变	规程每年改版, 物性数据库在更新	RAG (第四讲)
回答要有出处	安全规程问答必须指出条款号	RAG, 引用原文
要实时数据	“三号反应器现在多少度”	工具调用 (第五、六讲)
数据太少太差	只有 20 份报告, 还多是初稿	Prompt + Few-shot
没有授权	合作企业的工艺参数、未发表数据	先解决授权, 否则不做
用得很少	一年只写几次的申报材料	写好 Prompt 就够

第二讲那句话再说一遍: **先 Prompt, 再 RAG, 最后才考虑微调。**

原文把“盲目微调而不先评估更简单的方法”列为第一个常见误区。

Q:把规程“微调进”模型, 规程明年改版了, 模型会怎样? 你怎么知道它还记着旧版?

微调不是替代, 是分工: 报告助手的完整方案



原文的说法: 动态知识用 RAG, 稳定知识纳入微调。

写法、术语、格式、分寸是 **稳定的习惯** → 进参数; 新文献、本次实验数据是 **会变的内容** → 走输入。

不管哪一层, 最后都要人核对——微调让它“像我们组写的”, 不保证“数据是对的”。

小组判断：这五个需求，该不该微调？

课堂互动⑥ · 4 人一组，4 分钟，每题给“微调 / 不微调”和一句理由

1. 炼厂想让 AI 按公司模板写每日生产日报，格式十几年没变，每天要写 30 份。
2. 研究生想让 AI 回答“最新一期期刊里有哪些加氢催化剂的新进展”。
3. 实验室想让 AI 在学生问“这个废液能不能直接倒”时，永远先按安全规程拒绝并给出处理办法。
4. 课题组只有 15 份往年报告，想让 AI 模仿组内风格。
5. 某合作企业把未公开的装置运行数据发给课题组，想顺手拿来训练报告助手。

参考：

- ① ✓ 格式稳定、调用频繁、样本充足——典型的微调场景 (LoRA 即可)
- ② ✗ 知识在变，用 RAG 或联网检索；微调进去的“最新”第二个月就过时
- ③ 可以 先用 Prompt + RAG 引规程条款；仍偶尔“放行”时，再用拒答样本微调加固
- ④ ✗ 数据太少，先用 Few-shot 放两三份范例
- ⑤ ✗ 没有训练授权，与效果无关，先停下来问老师和合同

数据的边界: 能拿来训练的, 才拿来训练

- ▶ **授权先于效果**: 课题组报告、合作企业数据、他人未发表结果, 用于训练前要得到老师和数据所有方同意;
- ▶ **脱敏彻底**: 姓名、学号、联系方式、企业工艺参数删干净——模型可能把训练集里的原句吐出来;
- ▶ **训练数据也要可追溯**: 每条样本记下来源报告, 出了问题能查、能删、能重训;
- ▶ **署名诚实**: 用微调后的模型写报告、写论文, 要说明 AI 参与了哪些部分, 数据和结论仍由自己负责。

这些要求和实验室的数据管理规定是一回事: **原始数据要留底, 引用要注明, 保密的不外传。**

Q:讨论 (2 分钟): 用师兄师姐的毕业论文做训练数据, 需要问谁? 如果他们已经毕业了呢?

回到开场的投票: 报告助手, 到底该怎么办?

开场的四个选项: A. Prompt 再长一倍 B. RAG 再塞 100 份 C. 换更大的模型 D. 微调

A、B 为什么不够 问题是“术语不统一、格式每次不同”——是**习惯**问题, 不是缺信息; Prompt 和 RAG 改的是输入, 管不住每一次输出

C 为什么不划算 更大的模型更聪明, 但它同样没见过“我们组的写法”, 还更贵

D 的前提 Prompt 已写到位、RAG 已接好; 有 200 份定稿报告且得到授权; 全组每届都在用


怎么做 800 对样本 → SFT + QLoRA → 看验证 loss 早停 → 老师盲评 → 两人试岗 → 收错例增量训练

所以答案是 **D**, 但必须是在 **A、B 做过之后的 D**; 而且上线后, RAG 和人工核对一个都不能少。

现在再投一次票, 和开场时比, 你的选择变了吗?

本讲总结：带新人的四步，一条底线，一笔账

微调改的是参数,学的是习惯(风格 / 格式 / 术语 / 分寸)
会变的知识交给 RAG, 本次需求交给 Prompt, 实时数据交给工具



三句话带走: 微调改的是**参数**, 不是输入; 该微调的时候, 是 Prompt 和 RAG 都试过、**风格 / 格式**仍不稳定;
微调解决不了的, 是**天天变**的知识、**实时**的数据和跨轮的**记忆**。

随堂快测

课堂互动 · 3 道题

Q1 (单选) 下面哪个需求**最适合**用微调解决?

A. 回答本月新发布的国家标准 B. 让输出始终符合组内报告格式和术语

C. 查询反应器实时温度 D. 记住上一轮对话里用户说过的偏好

Q2 (判断) 训练 loss 一直在下降, 说明模型越训越好, 应该继续训练。

Q3 (简答) 课题组用 800 对样本做 LoRA 微调, 测试集分数很高, 上线后却频繁照搬旧报告的数字。给出两个可能原因。

答案: Q1 选 **B** (A 用 RAG, C 用工具调用, D 靠上下文工程);

Q2 **✗** 错误, 要同时看验证 loss, 它抬头就说明过拟合, 应早停;

Q3 训练轮数过多导致过拟合、背下原句; 按段落随机切分, 同一份报告同时出现在训练集和测试集, 测试分数虚高。

线上提交, 当堂出分。

七个词, 各用一句话带走

微调 (Fine-tuning)	在预训练模型上用自己的数据再训几轮, 改的是参数
LoRA / QLoRA	冻结原参数, 只训练旁边约 1% 的小矩阵; QLoRA 再把基础模型压到 4 位
SFT	用“指令—回答对”做监督训练, 学格式和写法
RLHF / DPO	用人的偏好打分, 教模型“哪种回答更合适”
训练 / 验证 / 测试集	用来学的 / 用来决定何时停的 / 只在最后考一次的
过拟合	训练集上全对、新数据上出错: 背答案, 没学会方法
早停	验证 loss 不再下降就停, 保存最好的那一版

Q:回到开场: 老师说“不像我们组的报告”, 现在你能说清这句话对应的是哪一种问题、该在哪一层解决吗?

课后任务与拓展

- 必做① 做 20 条教材: 从你自己写过的一份实验报告里, 按本讲的方法拆出 20 对“指令—回答”(含 2 条拒答样本), 写成 JSONL, 完成脱敏, 并用第三部分的八问检查单自查。
- 必做② 判断题作文: 从互动⑥里任选一个“不微调”的需求, 用 300 字说明该用什么方案、为什么, 以及在什么条件变化后它会变成“该微调”。
- 选做③ 看一次训练: 在 [阿里云百炼](#) 模型调优页面, 或 [LLaMA-Factory](#) 的示例里, 找到学习率、轮数、LoRA 秩这三个设置的位置并截图, 说明默认值是多少。

拓展阅读: 公众号合集《轻松读懂 AI 大模型》[第九篇](#);
[LoRA 论文 \(arXiv: 2106.09685\)](#) 第 1、4 节; [微调综述 \(arXiv: 2408.13296\)](#) 中七阶段流程一章 (选读)。

下讲预告: AI 能力选择指南——从需求到方案的完整决策路

工具已经齐了

Prompt、RAG、Function Call、MCP、Agent、上下文工程、微调, 九讲下来一件不少

难的是选

同一个需求可能有六七种做法, 选错了几小时的事拖成几个月

先问六个问题

任务类型、数据在哪、多新、错了会怎样、预算、安全合规

再走六步决策树

每一步对应前面的一讲, 走完得到一个能力组合

化工需求现场出方案

文献综述、DCS 异常解释、安全规程问答 ...各走一遍

Q:课前思考: 想一个你真希望有 AI 帮忙的化工需求, 写一句话带来——下节课我们就拿它走决策路。

