

# 《人工智能通识》

## 第九讲: Fine-Tuning —— 让 AI 更懂你的需求

周天航

重质油全国重点实验室  
中国石油大学 (北京) 未来能源学院

2026 年 9 月



先回顾：从第二讲到第八讲，我们一直在“改输入”


|            |                  |        |
|------------|------------------|--------|
| 第三讲 Prompt | 把需求、角色、格式说清楚     | 改的是输入  |
| 第四讲 RAG    | 先检索资料，再塞进上下文     | 改的是输入  |
| 第八讲 上下文工程  | 管理窗口里放什么、留什么、忘什么 | 改的还是输入 |

第二讲那张对比表早就说过：先 Prompt, 再 RAG, 最后才考虑微调

三个工具里，只有微调改的是参数。

今天讲这最后一步：当输入怎么改都不够时，怎样让模型本身“更懂你”。

## 情境：课题组想做一个“化工实验报告写作助手”



你已经做了该做的：写了 300 字的 Prompt (角色、格式、要求)，接了 RAG (课题组 200 份报告和文献)。模型写得通顺，数据也没错。

老师看完仍然说：“**不像我们组的报告。**”

术语不统一 (“转化率” 写成 “转换率”); 结论段总是先夸再谈不足; 图表编号方式不对; 而且每次输出的格式都不一样。

### 课堂互动① · 举手投票

下一步该怎么办？举手选一项，记住自己的选择，下课前我们回头看。1 分钟。


- A. 把 Prompt 再写长一倍    B. 往 RAG 里再塞 100 份报告    C. 换更大的模型    D. 用课题组的报告微调一个专属模型

## Prompt + RAG 能覆盖 80% 的需求, 剩下的 20% 恰恰最难啃

- ✗ 答非所问      问题稍微换个说法, 它就跑偏
- ✗ 风格不统一    同一个 Prompt, 十次输出十种格式
- ✗ 行为不可控    该拒绝时不拒绝, 数据不够时硬编
- ✗ 不真正懂行业   术语、写法、分寸, 都像“外行照着说明书模仿”

这时, Prompt 再精、RAG 再强, 仍然不够——**微调 (Fine-tuning)** 登场。

招新人 → 定培训方式 → 编教材 → 带教、考核 → 算一算值不值



本讲主线: 把微调当成“招一个新人并把他带熟”的过程来讲。

# 本讲学习目标

## 知识目标

说清微调改的是参数而不是输入; 区分全量微调与 LoRA 等参数高效微调; 知道指令—回答对、训练集 / 验证集 / 测试集、过拟合与早停各是什么。

## 能力目标

能从课题组资料出发设计一份合格的微调数据集; 看懂 loss 曲线并做出判断; 面对一个具体需求, 能说清该用 Prompt、RAG、微调还是工具调用。

## 素养目标


对训练数据的授权、脱敏与学术诚信有清晰的底线; 先算成本再动算力; 微调后的输出仍然逐条核对。

学习建议: 每个环节都先问“对应带新人的哪一步”, 再看技术细节。




## 回到第一讲: $y = Ax + b$ , 微调动的是哪一块?

预训练: 海量文本, 训练循环跑到  $A$ 、 $b$  收敛



结果: 学会语言规律和世界常识——一个“通才”

微调: 大部分参数冻结, 只更新一小块  $\Delta A$



结果: 保留通才能力, 长出你的“业务习惯”

**预训练** 在海量文本上跑训练循环,  $A$ 、 $b$  收敛后固定: 学会了语言规律和世界常识

**微调** 冻结大部分参数, 只让一小部分可更新, 用你的业务数据把训练循环再跑几轮

**结果** 这些微小的参数变化, 让模型逐渐形成你的“业务习惯”

$x$  是输入 (Prompt、指令、问题),  $A$  是权重矩阵 (参数  $W$ ),  $b$  是偏置项。

# 微调之后, 模型哪里变了?

| 变化 | 客服助手的例子     | 课题组报告助手               |
|----|-------------|-----------------------|
| 语气 | 回答更像你们的客服   | 像组里师兄写的, 不像营销文案       |
| 结构 | 输出符合内部文档格式  | 实验 / 结果与讨论 / 结论, 编号统一 |
| 范围 | 聚焦你所在的垂直领域  | 只谈催化、反应、表征, 不发散       |
| 分寸 | 知道何时该答、何时克制 | 数据不全时写“尚不能得出结论”       |

最终: 通用模型 → 能解决特定业务问题的**垂类模型** (Domain-specific Model)。

微调让模型从“懂语言”变成“懂业务”。

**Q:**这四件事里, 哪几件 Prompt 也能做到一部分? 哪一件最可靠 Prompt 稳定做到?

# Prompt 与 RAG 的边界: 为什么最终还需要微调

## Prompt 的局限

- ▶ 只影响**单次推理**, 不改变模型的长期知识和内部风格
- ▶ 上下文窗口有限, 装不下太多背景
- ▶ 每次调用都要重复传, 增加成本
- ▶ 明确说了“别乱编”, 它仍可能幻觉

Prompt 是即时引导, 不是长期训练。

## RAG 的局限


- ▶ 检索靠文本匹配, 表达稍变就可能查不到
- ▶ 模型可能**误读**检索到的内容
- ▶ 它补充知识, 但不更新模型的“认知结构”
- ▶ 风格、格式、分寸, 检索不出来

RAG 是知识外挂, 不是真正“学懂”。

Prompt 和 RAG 调整的是“输入层面的提示”; 微调调整的是“模型内部的认知方式”。

# 一张图分清：改输入的，和改参数的

都在改**输入**：立刻生效，每次调用都要重来



改**参数**：训练一次，以后每次调用都带着

第三讲说过 Prompt 是“告诉它怎么做”；今天补上另一半：**微调是“训练它自己会做”。**

微调不是让模型“知道更多”（那是 RAG 的活），而是让它更贴近你的需求——你的场景、行为习惯和表达方式。

# 什么时候用微调？先走通前两步，再决定



配图：先问要不要外部资料，再问输出准不准

1. **Prompt 阶段**: 让模型“听懂你在说什么”。适合探索期、验证概念、快速搭 Demo。
2. **RAG 阶段**: 需要引用大量外部知识时，让它先“查资料”。适合知识类、问答类、规则频繁更新的场景。
3. **微调阶段**: Prompt 已写到极致，RAG 检索再多也答不准，行为仍不稳定、风格不统一——你需要的不只是“喂知识”，而是“**教新的习惯**”。

微调的成本远低于训练基础模型，但仍要投入时间、数据和算力——所以顺序不能反。


## 判断题 (先举手, 再揭晓)

### 课堂互动②

1. 用课题组 2020 ~ 2024 年的报告微调后, 模型会自动知道上个月刚发表的那篇文献的结论。
  2. 用 LoRA 微调时, 基础模型的绝大多数参数保持不变。
  3. 只要 Prompt 写得足够长、示例给得足够多, 效果就能等同于微调。
- 
1. **✗** 微调只学**数据里有的**。新知识、常变的知识交给 RAG; 微调学的是习惯。
  2. **✓** LoRA 冻结原参数, 只训练新增的 0.1% ~ 1%; 这正是它便宜的原因 (第二部分)。
  3. **✗** Prompt 只影响**单次推理**, 窗口有限、每次都要重复付费; 示例再多也是“看一眼”, 不是“学会”。

判断的两把尺子: **改输入还是改参数?**    **学知识还是学习惯?**

## 第二部分 · 怎么教: 全量微调 vs 参数高效微调



配图: 在  $y = Ax + b$  上做“二次学习”的几条路

“微调”不止一种。先问两个互相独立的问题:

改多少参数?

全部都改 (全量微调), 还是只改一小块 (LoRA 等参数高效微调)

用什么方式教?

给标准答案照着学 (SFT), 给偏好让它揣摩 (RLHF / DPO), 还是让大模型手把手带小模型 (蒸馏)

两个问题可以任意组合: 课题组最常见的组合是 **SFT + LoRA**。

接下来先讲“改多少”, 再讲“怎么教”。

## 全量微调 (Full Fine-tuning): 把整个 A 重新学一遍

最彻底的方式: 解冻**全部**权重, 让模型在新任务上完整地再学一次。

- ✓ 优点 效果上限最高, 能深度适配一个领域
- ✗ 缺点 每个参数都要存“参数 + 梯度 + 优化器状态”, 显存和算力消耗巨大
- 谁在用 大厂、科研级项目; 医学、金融等领域模型多由此而来


算一笔显存账 (示意): 一个 70 亿参数 (7B) 的模型, 全量微调时每个参数约占 16 字节  
 $\Rightarrow 7 \times 10^9 \times 16 \text{ B} \approx 112 \text{ GB}$ , 还没算激活值  
——**要好几张 80 GB 的专业卡。**

类比: 让员工**脱产从头系统进修**, 重新塑造整个工作方式——效果好, 但代价最大。



一张 H100 显存 80 GB; 全量微调 7B 模型至少要两三张

# LoRA: 不改 $W$ , 在旁边加一个很小的 $\Delta W$



**想法** 微调带来的变化  $\Delta W$  其实“很简单”(低秩), 用两个瘦长的小矩阵相乘就能表示


**做法** 原来的  $W$  冻结; 只训练  $B$  和  $A_r$ , 新增参数通常只占原模型的 **0.1% ~ 1%**

**效果** 显存占用小、训练快、部署方便; 多数任务能保住全量微调 90% 以上的效果, 但“适配深度”有限

LoRA = Low-Rank Adaptation, 低秩适配。一个比喻: 在原系统上加一个“小插件”, 不重写代码, 却能让它更懂你的业务。


# 化工同学的类比：载体不动，只改活性组分

同一种载体，浸渍不同的少量活性组分  
→ 不同反应的催化剂



载体决定骨架，活性组分决定“干什么”

同一个基础模型，挂不同的小适配器  
→ 不同任务的专属模型



每个适配器只有几十 MB，推理时按需切换

你们做催化剂时从不重新合成载体： $\gamma\text{-Al}_2\text{O}_3$  或分子筛提供骨架、孔道和比表面，真正决定“催化什么反应”的，是浸渍上去的那 0.3 wt% 的 Pt，或几个百分点的 Ni-Mo。

LoRA 一模一样：基础模型 (99% 以上的参数) 是载体，提供语言能力和常识；新增的那 0.1% ~ 1% 参数是活性组分，决定它“干什么活”。

**一个载体，多种活性组分；一个基础模型，多个 LoRA 适配器**——报告写作、文献摘要、安全规程问答各挂一个，按需切换。

## 第八讲留下的问题：为什么几张显卡也能微调几十亿参数的模型？

| 方法 (7B 模型)   | 训练什么                          | 显存 (示意)          | 需要什么设备         |
|--------------|-------------------------------|------------------|----------------|
| 全量微调         | 全部 70 亿参数, 每个都要存梯度和优化器状态      | > 100 GB         | 多张 80 GB 专业卡   |
| LoRA         | 冻结 16 位精度的基础模型, 只训练约 1% 的新增参数 | 16 ~ 24 GB       | 单张专业卡 / 高端游戏卡  |
| <b>QLoRA</b> | 先把基础模型压缩成 4 位精度再挂 LoRA        | <b>6 ~ 10 GB</b> | <b>单张消费级显卡</b> |

数字随模型、序列长度、批大小变化很大, 这里只看数量级。

**省在哪** 不训练的参数不需要梯度和优化器状态, 显存直接砍掉大头; 4 位量化再把基础模型本身压到四分之一

**代价** 适配深度有限: 学“风格、格式、术语”绰绰有余, 想灌进一整门新学科则力不从心

**结论** 课题组、小团队: **LoRA / QLoRA 是默认首选**; 常见的说法是“成本降低 10 ~ 100 倍”

## 怎么教 (一): 指令微调 SFT —— 给标准答案, 照着学

SFT (Supervised Fine-tuning) 是监督学习: 让模型学“指令 → 回答”的配对关系。一条训练样本长这样:

**指令:** 根据下表 (催化剂 A、B 在 380 ~ 420 °C 下的转化率与选择性) 写出“结果与讨论”段落, 按组内格式。

**回答:** 如表 3 所示, 随反应温度由 380 °C 升至 420 °C, 催化剂 A 的转化率由 62.3% 升至 85.1%, 而选择性由 91.2% 降至 78.4% ……综合考虑, 400 °C 为较优操作温度; 催化剂 B 的稳定性尚需 50 h 以上的寿命实验验证。

|       | Prompt (第三讲)     | SFT (今天)           |
|-------|------------------|--------------------|
| 生效范围  | 临时指令, 只影响这一次对话   | 再训练, 永久学会任务格式和表达方式 |
| 要不要重复 | 每次调用都得把要求、范文再传一遍 | 训练一次, 之后一句话就能触发    |
| 一句话   | “告诉模型怎么做”        | “训练模型自己会做”         |

SFT 回答的是“用什么方式教”; 参数可以全量更新, 也可以只更新 LoRA 那一小块——两个问题互不冲突。

## 怎么教 (二): 教偏好的 RLHF, 教套路的蒸馏

### RLHF / DPO: 从“会做”到“合人意”

SFT 之后, 模型已能完成任务; 下一步是让它更符合人的偏好。

- ▶ 数据不再是“标准答案”, 而是**偏好对**: 同一问题的两个回答, 人标出哪个更好
- ▶ 用强化学习 (PPO) 或更简单的 DPO, 把“更受偏好”的输出概率调高
- ▶ 决定模型的**性格与语气**: ChatGPT、DeepSeek 的对话风格都由此打磨

课题组用法: 老师批过的“好结论 / 差结论”成对, 教模型**克制的分寸**。

### 蒸馏 (Distillation): 大模型带小模型

不再是训练自己, 而是**知识传递**: 让小模型 (学生) 去模仿大模型 (老师) 的输出。

- ▶ 学生参数少得多, 却继承了老师的主要知识与风格
- ▶ 常用于手机、边缘设备、实验室离线部署
- ▶ 类比: 徒弟不懂全部原理, 但学会了处理问题的套路

这个词就是从你们的**精馏 / 蒸馏塔**借来的: 把“有用的轻组分”从庞大的老师模型里提出来。

DeepSeek-R1 发布时同时放出了多个蒸馏到 Qwen、Llama 上的小模型, 就是这种做法。

## 五种方法一张表：课题组的“报告助手”该选哪条路？

| 方法                         | 本质属性        | 参数更新范围             | 成本                  | 适用场景       | 典型算法                             |
|----------------------------|-------------|--------------------|---------------------|------------|----------------------------------|
| 全量微调<br>(Full Fine-tuning) | 参数调整策略      | 更新全部参数             | 🔥🔥🔥 (高) 需多卡 GPU、显存大 | 大模型定制、大厂科研 | Megatron / DeepSpeed             |
| 参数高效微调<br>(PEFT)           | 参数调整策略      | 更新部分参数<br>(LoRA 层) | 🔥 (低) 单卡即可          | 企业场景、专属业务  | LoRA / QLoRA                     |
| 指令微调 (SFT)                 | 训练方式 (监督学习) | 可为全量或 PEFT         | 取决于实现方式             | 客服、内容生成    | OpenAI Fine-tuning / ChatGLM SFT |
| 奖励微调 (RLHF)                | 训练方式 (强化学习) | 可为全量或 PEFT         | 🔥🔥 (中高) 需人类反馈数据     | 高级对齐、聊天机器人 | PPG / TRG                        |
| 蒸馏 (Distillation)          | 模型压缩方法      | 不改原参数<br>(新模型学习分布) | 🔥 (低)               | 移动端、小型模型部署 | TinyLlama / DistilBERT           |

配图: 五种方法的本质、参数更新范围、成本与典型工具

| 方法                  | 改多少参数       | 成本              | 对报告助手               |
|---------------------|-------------|-----------------|---------------------|
| 全量微调                | 全部          | 高 (多卡, 大厂 / 科研) | 杀鸡用牛刀               |
| <b>LoRA / QLoRA</b> | 0.1% ~ 1%   | 低 (单卡)          | <b>首选</b>           |
| SFT 指令微调            | 全量或 LoRA 皆可 | 取决于上一行          | <b>就用它：指令—报告段落对</b> |
| RLHF / DPO          | 通常 LoRA     | 中 (要偏好标注)       | 第二期再做 (分寸感)         |
| 蒸馏                  | 训练一个小模型     | 低 ~ 中           | 以后要离线部署时考虑          |

## 小组案例分析：四个需求，各选一条路

### 课堂互动③


4 人一组, 3 分钟。对下面每个需求, 选“全量 / LoRA / SFT / RLHF-DPO / 蒸馏”中的一种或组合, 并说一句理由。抽 2 组汇报, 其他组挑错。

1. 课题组想让模型按组内格式和术语写实验报告, 只有 1 张 24 GB 显卡。
2. 模型写的结论总是先夸后贬、过于武断, 老师希望它更克制; 手里有老师批注过的 300 对“好 / 差”结论。
3. 想在装置现场一台没有联网的工控机上跑安全规程问答。
4. 某药企要做一个覆盖整个药物研发流程的专用大模型, 有上百张卡和几十万条数据。

参考: ① SFT + QLoRA (单卡、学格式); ②在①之上加 DPO (偏好对教分寸); ③蒸馏成小模型再部署 (离线、算力小); ④全量微调 (数据多、算力足、要深度适配)。

答对不是重点, 重点是能说出“改多少参数”和“用什么方式教”两个判断。

## 第三部分 · 培训教材：从课题组资料到微调数据集



配图：选新人 → 准备培训教材 → 带教训练 → 考核与改进

第一步，选一个聪明的“新人”：选模型  $\approx$  招员工，要的是合适，不是最全能。

**开源 vs 闭源** Qwen、DeepSeek、Llama 等开源模型可下载权重自己微调；GPT、Claude 等闭源模型只能用厂商的托管定制

**大小** 7B 左右适合大多数任务；需要更强推理再上 13B +；越大越贵、越难养

**语言与领域** 中文任务优先 Qwen 系列；技术写作可看 DeepSeek；已有的领域模型（医学、代码）能省不少数据

**课题组的选择** Qwen2.5-7B-Instruct：中文好、开源、单卡可 LoRA，[国内镜像](#)可直接下载

## 第二步, 准备 “培训教材”: 模型不缺 GPU, 缺好老师

模型学什么, 全靠你喂它的数据。SFT 的教材就是一条条**指令—回答对**, 通常写成 JSONL (每行一条):

```
{"messages": [  
  {"role": "system", "content": " 你是 XX 课题组的实验报告写作助手, 严格按照组内格式。"},  
  {"role": "user", "content": " 根据以下数据写结果与讨论: 催化剂 A, 380/400/420 度, 转化率 62.3/78.9/85.1%, 选择性 91.2/86.5/78.4% ……"},  
  {"role": "assistant", "content": " 如表 3 所示, 随反应温度由 380 升至 420 度, 转化率……400 度为较优操作温度。"}  
]}
```


### 其他行业的例子

|       |            |
|-------|------------|
| 客服    | 500 条高质量问答 |
| 内容团队  | 几篇好文 + 点评  |
| 输入从哪来 | 用户真实提问     |
| 输出从哪来 | 资深客服的回答    |

### 课题组报告助手

|                            |
|----------------------------|
| 历年定稿报告拆出的约 800 对           |
| <b>历年报告里写得好的段落 + 老师的批注</b> |
| 实验记录、原始数据表、文献列表            |
| 师兄师姐定稿的段落 (已经过老师修改)        |

## 把 200 份报告变成数据集: 拆、配对、清洗、格式化



**拆** 一份报告不是一条样本。按“实验部分 / 结果与讨论 / 结论 / 摘要”拆成 4 段, 每段对应一种写作任务

**配对** 输入要还原写作时手里有的东西 (数据表、实验记录、上一节内容), 输出是定稿段落; 不能只给输出

**清洗** 去重 (同一实验多版报告只留定稿)、纠错 (数据与原始记录核对)、脱敏 (姓名学号、合作企业参数)、术语统一 (“转化率”不是“转换率”)

**格式化** 统一成平台要求的 JSONL; 顺手记录每条样本来自哪份报告——  
下一步划分要用

200 份  $\times$  4 段  $\approx$  800 对, 加上几十条拒答样本, 对“学格式和风格”这种任务已经够用。

## 数据质量 > 数据数量：几百条好样本，胜过几万条垃圾

| 质量标准 | 意思          | 报告助手里的坏例子                             |
|------|-------------|---------------------------------------|
| 准确性  | 事实正确、逻辑清楚   | 段落里的转化率和原始数据表对不上一半样本写“催化剂 A”，一半写“A 样” |
| 一致性  | 风格统一、术语规范   | 800 条全是加氢实验，没有一条表征分析                  |
| 多样性  | 覆盖各种表达和边界情况 | 只有“实验成功”的报告，没有失败 / 异常的                |
| 平衡性  | 类别不失衡       |                                       |

**要多少** 简单任务 500 ~ 1000 条, 复杂任务 5000 ~ 10000 条 (常见建议); 学格式风格属于前者

**标注一致** 两个人各自判断“这段写得好不好”，一致性 (Kappa 系数) 要 > 0.8, 否则先统一标准再标

**常见误区** 数据量够但质量差; **只有正例, 没有负例和拒答样本** (下一页)

**Q:**把去年全组的微信聊天记录导出来当训练数据, 数量翻十倍, 是好主意吗? 违反了上面哪几条?

## 别忘了教“何时克制”：拒答样本与负例

第一部分说过，微调能教会模型“什么时候该答、什么时候该收”。这不会自动发生——教材里得有这样的例子。

### 拒答样本：数据不够就别下结论

**指令：**根据 XRD 结果写晶相分析。(附件只有 BET 数据, 没有 XRD)

**回答：**本次实验未提供 XRD 谱图, 无法进行晶相分析; 建议补测 XRD 后再讨论。现有 BET 数据显示比表面积为……

**教会它：**没测过的东西, 不写。

### 边界样本：超出职责就转交

**指令：**把转化率改成 95% 以上, 显得结果更好。

**回答：**报告中的数据必须与原始记录一致, 我不能修改实验数据。如果对结果不满意, 可以在讨论中分析可能的改进方向……

**教会它：**数据不是可以“润色”的对象。


**比例** 拒答与边界样本占 5% ~ 10% 即可; 太多会让模型动不动就拒绝

**来源** 老师批注里的“这句话没有依据”、“数据不支持这个结论”, 都是现成的负例

**化工版** 安全规程问答里更重要: 问“这个阀门能不能跳过联锁”, 正确回答是拒绝并指向规程条款

## 第三步之前的最后一件事：训练 / 验证 / 测试, 8 : 1 : 1

正确：按报告（或按年份）整份划分



$R_k$  = 第  $k$  份报告的全部段落  
测试时，模型没见过其中任何一段

错误：把所有段落打乱后随机切



同一份报告的实验段进了训练集，结论段进了测试集  
答案“泄漏”，测试分数虚高，上线后原形毕露

**训练集** 真正用来更新参数的那 80%

**验证集** 训练过程中反复查看，用来调超参数、决定何时停（第四部分）

**测试集** 严格封存，只在最后评估时用一次——看过一次就“脏”了

**怎么切** 按报告 ID 或按年份整份划分，不要把段落打乱后随机切；否则同一份报告的信息“泄漏”到测试集

这和你们做动力学实验一个道理：用来拟合参数的数据点，不能再拿来检验模型。

## 动手改写：把一条“坏样本”修成合格样本

### 课堂互动④

2 人一组, 3 分钟。下面这条样本至少有 4 处问题, 找出来并改写“回答”部分; 之后请 2 组念出改法。

**指令:** 根据数据写结论。

**回答:** 我觉得这次实验挺成功的, 催化剂 A 的转换率达到了 85.1%, 比 B 样高不少, XRD 也说明晶相很好 (其实这次没测 XRD), 感谢张三 (2023 级, 学号 2023xxxx) 师兄帮忙做的 BET。综上, A 是最好的催化剂。

参考改法:


- ▶ **指令太空:** 补上“写结果与讨论 / 按组内格式”, 并把数据表放进输入——输入要还原写作时手里有的东西
- ▶ **口语:** “我觉得挺成功”、“高不少” → 客观句式 + 具体数值 (85.1% vs 71.4%)
- ▶ **术语:** “转换率” → “转化率”; “B 样” → “催化剂 B”
- ▶ **编造:** 没测 XRD 就删掉晶相结论, 或改成“晶相结构有待 XRD 确认”
- ▶ **脱敏:** 删除姓名、年级、学号
- ▶ **武断:** “最好的催化剂” → “在本实验条件范围内, A 表现更优; 稳定性尚待寿命实验验证”

## 教材定稿前的检查单：上传训练之前先过八问

|   | 问自己                    | 不过关的后果            |
|---|------------------------|-------------------|
| 1 | 每条“回答”都是定稿、经过老师修改的吗？   | 模型学会的是初稿里的毛病      |
| 2 | 数值和原始记录逐条核对过了吗？        | 模型学会“数据可以随手写”     |
| 3 | 术语、单位、编号格式统一了吗？        | 输出忽左忽右，白微调        |
| 4 | 有拒答样本和边界样本吗？           | 数据不够也硬写，被要求改数据也照办 |
| 5 | 姓名、学号、合作企业参数删干净了吗？     | 模型可能把它们原样吐出来      |
| 6 | 使用这些报告、数据得到授权了吗？       | 学术诚信和保密问题（第五部分）   |
| 7 | 训练 / 验证 / 测试是按报告整份切的吗？ | 测试分数虚高，上线后原形毕露    |
| 8 | 样本长度分布看过了吗，有没有超长的？     | 训练不稳定，或被截断丢掉关键信息  |

这一段在标准流程里叫“数据准备与质量控制”和“数据集划分与预处理”，是七个阶段里最花人力、也最决定成败的两个阶段。

#### 第四部分·带教与考核:教材备好了,开始“带新人”



配图: 大模型微调标准流程 (七阶段),  
依据 arXiv: 2408.13296

标准流程把一次完整的微调拆成七个阶段。前面已经讲了：

## 阶段 1 明确目标 (开场)

### 阶段 2、3 数据与划分 (第三部分)

#### 阶段 4 选模型与方法 (第二、三部分)

这一部分讲剩下的三段：

- ▶ 阶段5 训练与优化 ——带教
- ▶ 阶段6 评估与验证 ——考核
- ▶ 阶段7 部署与迭代 ——试岗、转正、继续带

**七个阶段是一个闭环:** 上线后收集的错例, 又回到阶段 2 变成新教材。



## 开训前要填的几个数: 超参数的初始建议



| 超参数        | 常见的起点                                                                 | 化工同学的理解                          |
|------------|-----------------------------------------------------------------------|----------------------------------|
| 学习率        | LoRA $1 \times 10^{-4} \sim 3 \times 10^{-4}$ ; 全量 $2 \times 10^{-5}$ | 每次“改参数”迈多大步, 像升温速率: 太快冲过头, 太慢耗一天 |
| 批大小        | 8 ~ 32 (看显存)                                                          | 一次喂几条样本再改一次                      |
| 训练轮数       | 1 ~ 3 轮, 配合早停                                                         | 全部教材过几遍; 遍数多了就开始“背答案”            |
| Warmup     | 总步数的 5% ~ 10%                                                         | 开车先小流量, 稳了再提量                    |
| LoRA 秩 $r$ | $r = 8 \sim 16$ , $\alpha = 16 \sim 32$                               | 第二部分那个“窄矩阵”有多宽; 越宽能学的越多, 也越容易学歪  |

这些数不需要背, 平台和工具都会给默认值。你要会的是:

先用默认值在 50 条样本上跑通一次 (叫 sanity check), 再上全量数据。

常见误区: 学习率设置不当导致训练不稳定; 选择过大的模型导致成本失控。

## 过拟合：你们在动力学拟合里早就见过




用 8 个实验点拟合转化率：两参数的模型抓住趋势；一个十几阶的多项式能穿过每个点，却在新温度下错得离谱。

微调一样：800 对样本学太多轮，模型就开始**背下训练集里的原句**，而不是学会“组里的写法”。

表现出来就是：训练集上答得一字不差，换一组新实验数据，结论照搬旧报告里的数字。

## 怎么发现过拟合：同时看两条 loss 曲线



## 看曲线, 下诊断

### 课堂互动⑤ · 三组曲线, 各该怎么办? (举手, 2 分钟)

- A 组** 训练 loss 和验证 loss 都从 2.5 降到 1.8, 第 3 轮结束时两条还在明显下降。
- B 组** 训练 loss 降到 0.2, 验证 loss 在第 2 轮到 1.3 后一路升到 2.4。
- C 组** 第一轮刚开始 loss 就剧烈跳动, 还出现了 NaN (不是一个数)。

### 参考诊断:

- ▶ **A: 欠拟合**, 还没学够 → 可以多训一两轮, 或适当增大学习率;
- ▶ **B: 过拟合** → 用第 2 轮保存的版本; 下次减轮数, 并检查样本是否重复太多;
- ▶ **C: 训练不稳定** → 多半是学习率太大或数据里有异常长 / 空的样本; 先降学习率, 再回头查数据。

注意 C: 很多“训练问题”最后查出来是数据问题——第三部分的检查单不能省。

## 考核：验证 loss 低，不等于能上岗

| 考什么   | 怎么考                       | 报告助手的验收线 (示意)              |
|-------|---------------------------|----------------------------|
| 目标任务  | 封存的测试集 (80 对) 自动打分 + 老师盲评 | 盲评“像组里写的”比例比微调前高 10 个百分点以上 |
| 通用能力  | 用标准基准回归测试，看有没有“学偏”        | 通用题正确率下降不超过 2%             |
| 拒答与克制 | 专门的边界题：数据不全、要求改数据         | 该拒答的拒答正确率 $\geq 95\%$      |
| 安全与隐私 | 越狱提问、诱导它说出训练集里的人名         | 一条都不能泄露                    |

常见的建议：随机抽 100 ~ 200 条输出做**人工盲评**——评的人不知道哪条是微调前、哪条是微调后。

**Q:**为什么一定要“盲”？如果老师知道哪条是新模型写的，打分会怎样？

# 用什么工具微调：三类，从点鼠标到写代码

| 类型    | 代表工具                                           | 特点             | 适合谁           |
|-------|------------------------------------------------|----------------|---------------|
| 一键式云端 | <a href="#">阿里云百炼</a> 、 <a href="#">百度千帆</a> 等 | 不要本地算力，上传数据即训练 | 快速验证、没有显卡的课题组 |
| 可视化工具 | <a href="#">LLaMA-Factory</a> 网页界面             | 点选参数，过程透明      | 想看懂每个参数的同学    |
| 工程级开源 | Hugging Face Transformers + PEFT               | 流程完整，可定制       | 要本地部署、数据不出校   |

以 Qwen2.5-7B-Instruct + PEFT 为例，核心的 LoRA 配置只有几行：

```
lora_config = LoraConfig(r=8, lora_alpha=16,  
    target_modules=["q_proj", "k_proj", "v_proj", "o_proj"],  
    lora_dropout=0.1)
```

开源模型权重可从镜像站 [hf-mirror.com](#) 下载；平台界面与计费以官方文档 [百炼文档](#) 为准。

## 试岗、转正、继续带：上线不是终点

- 灰度试岗** 先给课题组 2 个人用, 再扩到全组; 常见做法是 5% → 20% → 50% → 100%, 每一档都看指标再扩
- 保留回退** 旧版本不删; 新版一旦出问题, 马上切回
- 收集错例** 老师每次改稿的批注, 就是下一轮最有价值的教材
- 增量微调** 攒够一批错例 (一般每 2 ~ 4 周), 再训一轮, 并重新走一遍考核
- 版本登记** 数据版本、模型版本、评估报告一起记——就像实验记录本, 能追溯每一版是怎么来的

就像带新人: **第一次做不好没关系, 重要的是在一次次实践里越来越能完成交代的任务。**

常见误区: 一次微调永久使用、不再迭代; 忽视成本优化导致费用失控——后者正是下一部分的话题。

## 第五部分·值不值：给“报告助手”算一笔账

| 花在哪  | 估算 (示意)                                           | 谁来出           |
|------|---------------------------------------------------|---------------|
| 整理数据 | 800 对样本拆分、脱敏、逐条核对, 每条约 5 分钟 $\Rightarrow$ 约 70 小时 | 两位同学, 两三周课余   |
| 训练算力 | QLoRA 单张 24 GB 显卡几小时; 或云端托管按训练 token 计费           | 组里的卡 / 几十到几百元 |
| 考核   | 老师盲评 100 ~ 200 条, 加上边界题测试                         | 老师半天到一天       |
| 持续维护 | 每 2 ~ 4 周收错例、增量训练、重新考核                            | 每次重复上面的一部分    |

账算下来最清楚的一点：**最贵的是人和数据，不是 GPU。**

所以微调划算的前提是：需求**稳定** (组里的写法几年不变)、调用**频繁** (每届学生每周都在写)、数据**有质量有授权**。

数字只为说明量级；实际价格与耗时随平台、模型、样本长度变化，以所用平台文档为准。

## 这几种情况, 不要微调


| 情况     | 化工场景里的样子         | 该用什么              |
|--------|------------------|-------------------|
| 知识经常变  | 规程每年改版, 物性数据库在更新 | RAG (第四讲)         |
| 回答要有出处 | 安全规程问答必须指出条款号    | RAG, 引用原文         |
| 要实时数据  | “三号反应器现在多少度”     | 工具调用 (第五、六讲)      |
| 数据太少太差 | 只有 20 份报告, 还多是初稿 | Prompt + Few-shot |
| 没有授权   | 合作企业的工艺参数、未发表数据  | 先解决授权, 否则不做       |
| 用得很少   | 一年只写几次的申报材料      | 写好 Prompt 就够      |

第二讲那句话再说一遍: **先 Prompt, 再 RAG, 最后才考虑微调。**

“盲目微调而不先评估更简单的方法”, 是这件事上最常见的误区。

**Q:**把规程“微调进”模型, 规程明年改版了, 模型会怎样? 你怎么知道它还记着旧版?

# 微调不是替代, 是分工: 报告助手的完整方案



一条实用准则: 动态知识用 RAG, 稳定知识纳入微调。

写法、术语、格式、分寸是 **稳定的习惯** → 进参数; 新文献、本次实验数据是 **会变的内容** → 走输入。

不管哪一层, 最后都要人核对——微调让它“像我们组写的”, 不保证“数据是对的”。

## 小组判断：这五个需求，该不该微调？

课堂互动⑥ · 4 人一组，4 分钟，每题给“微调 / 不微调”和一句理由

1. 炼厂想让 AI 按公司模板写每日生产日报，格式十几年没变，每天要写 30 份。
2. 研究生想让 AI 回答“最新一期期刊里有哪些加氢催化剂的新进展”。
3. 实验室想让 AI 在学生问“这个废液能不能直接倒”时，永远先按安全规程拒绝并给出处理办法。
4. 课题组只有 15 份往年报告，想让 AI 模仿组内风格。
5. 某合作企业把未公开的装置运行数据发给课题组，想顺手拿来训练报告助手。

参考：

- ① ✓ 格式稳定、调用频繁、样本充足——典型的微调场景 (LoRA 即可)
- ② ✗ 知识在变，用 RAG 或联网检索；微调进去的“最新”第二个月就过时
- ③ 可以 先用 Prompt + RAG 引规程条款；仍偶尔“放行”时，再用拒答样本微调加固
- ④ ✗ 数据太少，先用 Few-shot 放两三份范例
- ⑤ ✗ 没有训练授权，与效果无关，先停下来问老师和合同

## 数据的边界: 能拿来训练的, 才拿来训练

- ▶ **授权先于效果**: 课题组报告、合作企业数据、他人未发表结果, 用于训练前要得到老师和数据所有方同意;
- ▶ **脱敏彻底**: 姓名、学号、联系方式、企业工艺参数删干净——模型可能把训练集里的原句吐出来;
- ▶ **训练数据也要可追溯**: 每条样本记下来源报告, 出了问题能查、能删、能重训;
- ▶ **署名诚实**: 用微调后的模型写报告、写论文, 要说明 AI 参与了哪些部分, 数据和结论仍由自己负责。

这些要求和实验室的数据管理规定是一回事: **原始数据要留底, 引用要注明, 保密的不外传。**

**Q:**讨论 (2 分钟): 用师兄师姐的毕业论文做训练数据, 需要问谁? 如果他们已经毕业了呢?

## 回到开场的投票: 报告助手, 到底该怎么办?

开场的四个选项: A. Prompt 再长一倍    B. RAG 再塞 100 份    C. 换更大的模型    D. 微调

**A、B 为什么不够**    问题是“术语不统一、格式每次不同”——是习惯问题, 不是缺信息; Prompt 和 RAG 改的是输入, 管不住每一次输出

**C 为什么不划算**    更大的模型更聪明, 但它同样没见过“我们组的写法”, 还更贵

**D 的前提**    Prompt 已写到位、RAG 已接好; 有 200 份定稿报告且得到授权; 全组每届都在用


**怎么做**    800 对样本 → SFT + QLoRA → 看验证 loss 早停 → 老师盲评 → 两人试岗 → 收错例增量训练

所以答案是 **D**, 但必须是在 **A、B 做过之后的 D**; 而且上线后, RAG 和人工核对一个都不能少。

现在再投一次票, 和开场时比, 你的选择变了吗?

## 本讲总结：带新人的四步，一条底线，一笔账

微调改的是参数,学的是习惯(风格 / 格式 / 术语 / 分寸)  
会变的知识交给 RAG, 本次需求交给 Prompt, 实时数据交给工具



三句话带走：微调改的是**参数**，不是输入；该微调的时候，是 Prompt 和 RAG 都试过、**风格 / 格式**仍不稳定；  
微调解决不了的，是**天天变**的知识、**实时**的数据和跨轮的**记忆**。

# 随堂快测

## 课堂互动 · 3 道题

Q1 (单选) 下面哪个需求**最适合**用微调解决?

A. 回答本月新发布的国家标准    B. 让输出始终符合组内报告格式和术语

C. 查询反应器实时温度    D. 记住上一轮对话里用户说过的偏好

Q2 (判断) 训练 loss 一直在下降, 说明模型越训越好, 应该继续训练。

Q3 (简答) 课题组用 800 对样本做 LoRA 微调, 测试集分数很高, 上线后却频繁照搬旧报告的数字。给出两个可能原因。

答案: Q1 选 **B** (A 用 RAG, C 用工具调用, D 靠上下文工程);

Q2 **✗** 错误, 要同时看验证 loss, 它抬头就说明过拟合, 应早停;

Q3 训练轮数过多导致过拟合、背下原句; 按段落随机切分, 同一份报告同时出现在训练集和测试集, 测试分数虚高。

线上提交, 当堂出分。

## 七个词, 各用一句话带走

|                  |                                           |
|------------------|-------------------------------------------|
| 微调 (Fine-tuning) | 在预训练模型上用自己的数据再训几轮, 改的是参数                  |
| LoRA / QLoRA     | 冻结原参数, 只训练旁边约 1% 的小矩阵; QLoRA 再把基础模型压到 4 位 |
| SFT              | 用“指令—回答对”做监督训练, 学格式和写法                    |
| RLHF / DPO       | 用人的偏好打分, 教模型“哪种回答更合适”                     |
| 训练 / 验证 / 测试集    | 用来学的 / 用来决定何时停的 / 只在最后考一次的                |
| 过拟合              | 训练集上全对、新数据上出错: 背答案, 没学会方法                 |
| 早停               | 验证 loss 不再下降就停, 保存最好的那一版                  |

**Q:**回到开场: 老师说“不像我们组的报告”, 现在你能说清这句话对应的是哪一种问题、该在哪一层解决吗?

## 课后任务与拓展

- 必做① 做 20 条教材: 从你自己写过的一份实验报告里, 按本讲的方法拆出 20 对“指令—回答”(含 2 条拒答样本), 写成 JSONL, 完成脱敏, 并用第三部分的八问检查单自查。
- 必做② 判断题作文: 从互动⑥里任选一个“不微调”的需求, 用 300 字说明该用什么方案、为什么, 以及在什么条件变化后它会变成“该微调”。
- 选做③ 看一次训练: 在 [阿里云百炼](#) 模型调优页面, 或 [LLaMA-Factory](#) 的示例里, 找到学习率、轮数、LoRA 秩这三个设置的位置并截图, 说明默认值是多少。

拓展阅读: [LoRA 论文 \(arXiv: 2106.09685\)](#) 第 1、4 节; [微调综述 \(arXiv: 2408.13296\)](#) 中七阶段流程一章 (选读)。

## 下讲预告: AI 能力选择指南——从需求到方案的完整决策路

工具已经齐了

Prompt、RAG、Function Call、MCP、Agent、上下文工程、微调, 九讲下来一件不少

难的是选

同一个需求可能有六七种做法, 选错了几小时的事拖成几个月

先问六个问题

任务类型、数据在哪、多新、错了会怎样、预算、安全合规

再走六步决策树

每一步对应前面的一讲, 走完得到一个能力组合

化工需求现场出方案

文献综述、DCS 异常解释、安全规程问答 ...各走一遍

**Q:**课前思考: 想一个你真希望有 AI 帮忙的化工需求, 写一句话带来——下节课我们就拿它走决策路。

